

# Tiesinių lygčių sistemų sprendimas (3)

[http://oras.if.ktu.lt/moduliai/T170B115/Skaitiniai inžinerijos metodai su MATLAB  
\(KP RG RB\)2009](http://oras.if.ktu.lt/moduliai/T170B115/Skaitiniai_inzinerijos_metodai_su_MATLAB_(KP_RG_RB)2009)

F7.pdf - 4.1-4.5 poskyriai

[http://oras.if.ktu.lt/moduliai/T170B115 /Skaitiniai inžinerijos metodai\(RB\) 2006](http://oras.if.ktu.lt/moduliai/T170B115/Skaitiniai_inzinerijos_metodai(RB)_2006)

l.1.2.pdf

## Prisiminkime: skaitiniai tiesinių algebrinių lygčių sistemų sprendimo metodai

- *Tiesioginiai* – sprendinys gaunamas algeбриškai pertvarkant lygčių sistemą (t.y. koeficientų matrica skaičiuojant pertvarkoma)
- ***Iteraciniai* – koeficientų matrica išlieka nepakitusi. Sprendinį apskaičiuojame nuosekliaisiais priartėjimais**

# ***Paprastųjų iteracijų* algoritmo taikymas tiesinių lygčių sistemai (1)**

$$[\mathbf{A}] \quad \{\mathbf{x}\} = \{\mathbf{b}\}$$

$$\begin{bmatrix} a_{11} & a_{12} & a_{23} \\ a_{12} & a_{22} & a_{23} \\ a_{22} & a_{23} & a_{33} \end{bmatrix} \begin{Bmatrix} x_1 \\ x_2 \\ x_3 \end{Bmatrix} = \begin{Bmatrix} b_1 \\ b_2 \\ b_3 \end{Bmatrix};$$

Jeigu įstrižainėje yra “0” reikšmė, reikia sukeisti vietomis kintamuosius. Pavyzdžiui, sukeitus vietomis kintamuosius  $x_2$  ir  $x_3$ , susikeičia vietomis 2-as ir 3-ias matricos  $A$  stulpeliai

$$\begin{bmatrix} 1 & \frac{a_{12}}{a_{11}} & \frac{a_{23}}{a_{11}} \\ \frac{a_{21}}{a_{22}} & 1 & \frac{a_{23}}{a_{22}} \\ \frac{a_{31}}{a_{33}} & \frac{a_{32}}{a_{33}} & 1 \end{bmatrix} \begin{Bmatrix} x_1 \\ x_2 \\ x_3 \end{Bmatrix} = \begin{Bmatrix} \frac{b_1}{a_{11}} \\ \frac{b_1}{a_{22}} \\ \frac{b_1}{a_{33}} \end{Bmatrix};$$

Metodas konverguoja greičiau, kai įstrižainėje yra absoliutiniu dydžiu didesni koeficientai

# Paprastųjų iteracijų algoritmo taikymas tiesinių lygčių sistemai (2)

Laisvai parinktas skaičius, nuo kurio galėtų priklausyti konvergavimo greitis. Dažniausiai priimama  $\alpha=1$

$$\alpha \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{Bmatrix} x_1 \\ x_2 \\ x_3 \end{Bmatrix} + \begin{bmatrix} 1-\alpha & \frac{a_{12}}{a_{11}} & \frac{a_{13}}{a_{11}} \\ \frac{a_{21}}{a_{22}} & 1-\alpha & \frac{a_{23}}{a_{22}} \\ \frac{a_{31}}{a_{33}} & \frac{a_{32}}{a_{33}} & 1-\alpha \end{bmatrix} \begin{Bmatrix} x_1 \\ x_2 \\ x_3 \end{Bmatrix} = \begin{bmatrix} \frac{b_1}{a_{11}} \\ \frac{b_1}{a_{22}} \\ \frac{b_1}{a_{33}} \end{bmatrix};$$

$$\alpha \{\mathbf{x}\} + [\tilde{\mathbf{A}}] \{\mathbf{x}\} = \{\tilde{\mathbf{b}}\}$$

$$\{\mathbf{x}\}^{(k+1)} = \frac{1}{\alpha} \left( \{\tilde{\mathbf{b}}\} - [\tilde{\mathbf{A}}] \{\mathbf{x}\}^{(k)} \right)$$

Paprastųjų iteracijų algoritmas

$\{\mathbf{x}\}^{(0)}$  - pradinis artinys

Iteracijų pabaigos sąlyga:

$$\frac{\left\| \left\{ \mathbf{x} \right\}^{(k+1)} - \left\{ \mathbf{x} \right\}^{(k)} \right\|}{\left\| \left\{ \mathbf{x} \right\}^{(k+1)} \right\| + \left\| \left\{ \mathbf{x} \right\}^{(k)} \right\|} < \varepsilon$$

# Paprastųjų iteracijų algoritmas

```
A=[ 1 -1  0  0;  
    -1  2 -1  0;  
     0 -1  2 -1;  
     0  0 -1  2]  
b=[2;0;0;0]  
n=size(A,1)
```

```
alpha=1; % metodo parametras  
Atld=diag(1./diag(A))*A-alpha*diag(ones(n,1));  
btld=diag(1./diag(A))*b;
```

```
nitmax=1000; eps=1e-12;
```

```
x=zeros(n,1); %pradinis artinys  
for it=1:nitmax  
    x1=btld-Atld*x;  
    tikslumas=norm(x1-x)/(norm(x)+norm(x1));  
    if tikslumas < eps, break, end  
    x=x1;  
end
```

A =

1	1	1	1
1	-5	-1	1
2	1	-10	2
3	1	2	-10

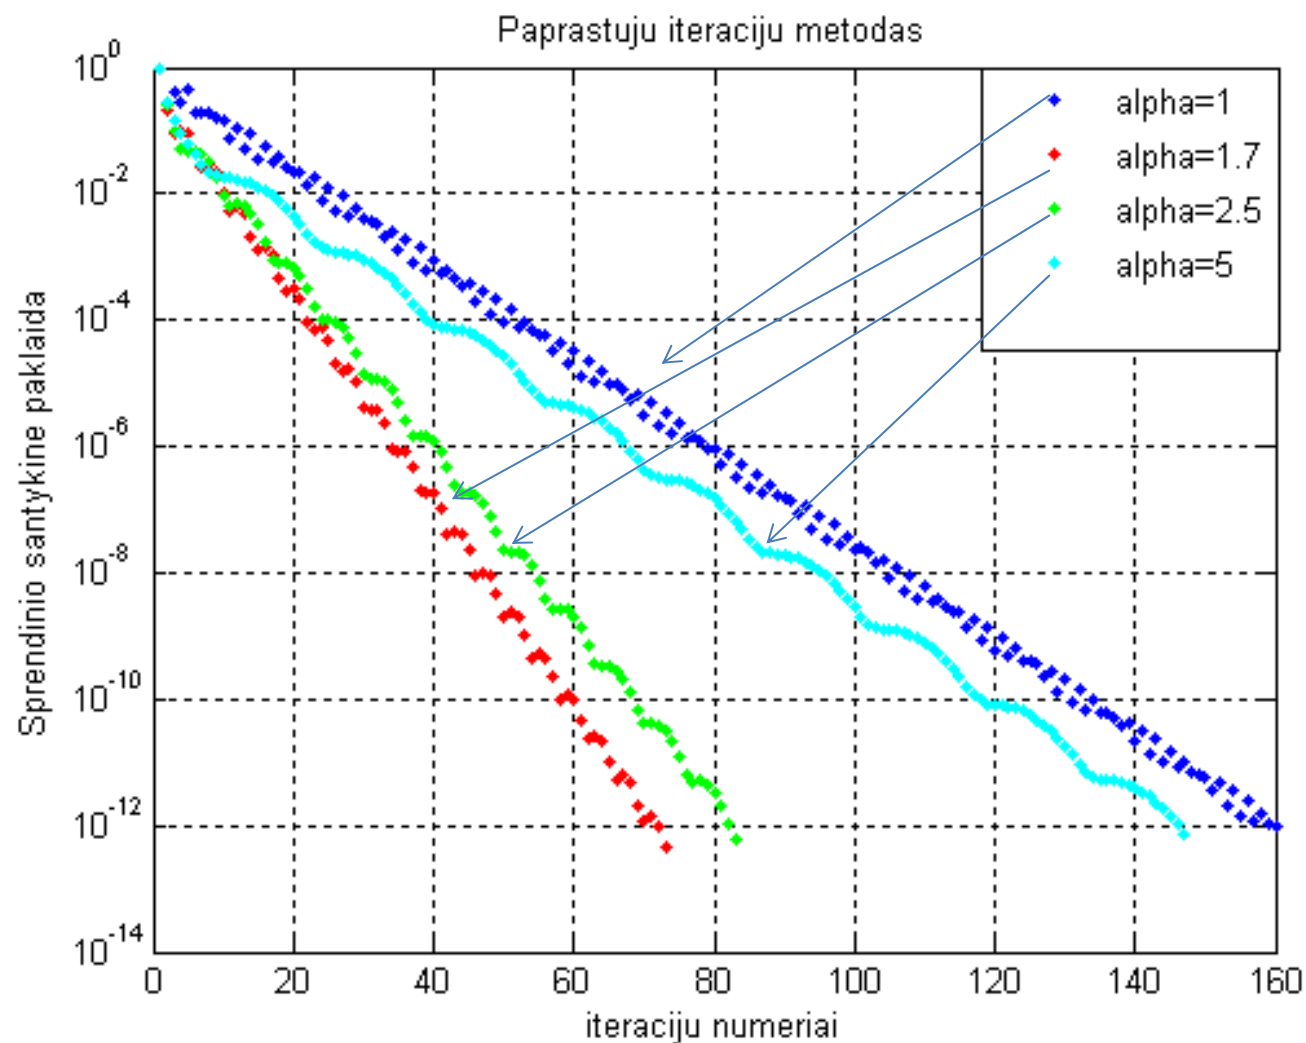
b =

2  
0  
9  
-7

x =

1.0110  
0.4857  
-0.4571  
0.9604

## Paprastųjų iteracijų metodo **konvergavimo greičiai** esant skirtingoms $\alpha$ reikšmėms



# ***Gauso-Zeidelio iteracijų* algoritmo taikymas tiesinių lygčių sistemai**

$$\{\mathbf{x}\}^{(k+1)} = \frac{1}{\alpha} \left( \{\tilde{\mathbf{b}}\} - [\tilde{\mathbf{A}}] \{\mathbf{x}\}^{(k)} \right)$$

Paprastųjų iteracijų algoritmas



$$x_i^{(k+1)} = \frac{1}{\alpha} \left( \tilde{b}_i - \sum_{j=1}^n \tilde{a}_{ij} x_j^{(k)} \right), \quad i = 1:n$$



$$x_i^{(k+1)} = \frac{1}{\alpha} \left( \tilde{b}_i - \sum_{j=1}^{i-1} \tilde{a}_{ij} x_j^{(k+1)} - \sum_{j=i}^n \tilde{a}_{ij} x_j^{(k)} \right), \quad i = 1:n$$

Gauso-Zeidelio iteracijų algoritmas



# Gauso-Zeidelio iteracijų algoritmas

```
A=[ 1  -1  0  0;  
    -1  2 -1  0;  
     0 -1  2 -1;  
     0  0 -1  2]
```

```
b=[2;0;0;0]
```

```
n=size(A,1)
```

```
alpha=1; % metodo parametras
```

```
Atld=diag(1./diag(A))*A- alpha*diag(ones(n,1));
```

```
btld=diag(1./diag(A))*b;
```

```
nitmax=1000; eps=1e-12;
```

```
x=zeros(n,1); %pradinis artinys
```

```
for it=1:nitmax
```

```
    for i=1:n
```

```
        x1(i)=(btld(i)- Atld(i,1:i-1)*x1(1:i-1)-Atld(i,i:n)*x(i:n))/alpha;
```

```
    end
```

```
    tikslumas=norm(x1-x)/(norm(x)+norm(x1));
```

```
    if tikslumas < eps, break, end
```

```
    x=x1;
```

```
end
```

A =

1	1	1	1
1	-5	-1	1
2	1	-10	2
3	1	2	-10


b =

2
0
9
-7

x =

1.0110
0.4857
-0.4571
0.9604

## Paprastųjų iteracijų ir Gauso-Zeidelio metodai: konvergavimo greičiai



## Kiti iteraciniai tiesinių lygčių sistemų sprendimo metodai

- Yra ir kitokių iteracinių metodų TLS spręsti – *jungtinių gradientų (funkcija `cjg`)*, *mažiausių kvadratų (funkcija `lsqr`)* ir kt.

Šie metodai gali būti taikomi bendruoju pavidalu saugomoms retosioms matricoms;

- Metodų matematinis veikimo principas paremtas funkcijos minimizavimo algoritmais. Dėl ribotos kurso apimties čia jų nenagrinėsime.

# Laisvųjų narių vektoriaus paklaidos įtaka sprendinio paklaidai

$$[\mathbf{A}](\{\mathbf{x}\} + \Delta\{\mathbf{x}\}) = \{\mathbf{b}\} + \Delta\{\mathbf{b}\}$$

$$[\mathbf{A}] \cdot \Delta\{\mathbf{x}\} = \Delta\{\mathbf{b}\}$$

- Reikia nustatyti kiekybinę skaliarinę įvertį, kaip laisvųjų narių vektoriaus paklaidos įtakoja sprendinio paklaidas;
- Panaudosime *matricos ir vektoriaus normų sąvokas*;

# Vektorių ir matricų normos

Pagal apibrėžimą, *norma yra matricą ar vektorių apibūdinantis skaičius*, tenkinantis tokias sąlygas:

$$\|[\mathbf{A}]\| \geq 0;$$

$$\|\alpha[\mathbf{A}]\| = \alpha \|[\mathbf{A}]\|;$$

$$\|[\mathbf{A}] + [\mathbf{B}]\| \leq \|[\mathbf{A}]\| + \|[\mathbf{B}]\|;$$

$$\|[\mathbf{A}] \cdot [\mathbf{B}]\| \leq \|[\mathbf{A}]\| \cdot \|[\mathbf{B}]\|;$$

Naudosime tokias normas:

$$\|[\mathbf{A}]\| = \sqrt{\sum_{i=1}^n \sum_{j=1}^n a_{ij}^2}; \quad \|\{\mathbf{x}\}\| = \sqrt{\sum_{i=1}^n x_i^2}$$

MATLAB-e:

`norm(A)`

`norm(x)`

# Laisvųjų narių ir sprendinio santykinų paklaidų tarpusavio priklausomybė

$$[\mathbf{A}](\{\mathbf{x}\} + \Delta\{\mathbf{x}\}) = \{\mathbf{b}\} + \Delta\{\mathbf{b}\}$$

$$[\mathbf{A}] \cdot \Delta\{\mathbf{x}\} = \Delta\{\mathbf{b}\}$$

$$\|\Delta\{\mathbf{x}\}\| = \|[\mathbf{A}]^{-1} \Delta\{\mathbf{b}\}\| \leq \|[\mathbf{A}]^{-1}\| \cdot \|\Delta\{\mathbf{b}\}\|$$

$$\|\{\mathbf{b}\}\| = \|[\mathbf{A}]\{\mathbf{x}\}\| \leq \|[\mathbf{A}]\| \cdot \|\{\mathbf{x}\}\|.$$

$$\|\Delta\{\mathbf{x}\}\| \cdot \|\{\mathbf{b}\}\| \leq \|[\mathbf{A}]\| \cdot \|[\mathbf{A}]^{-1}\| \cdot \|\Delta\{\mathbf{b}\}\| \cdot \|\{\mathbf{x}\}\|.$$

$$\frac{\|\Delta\{\mathbf{x}\}\|}{\|\{\mathbf{x}\}\|} \leq \|[\mathbf{A}]\| \cdot \|[\mathbf{A}]^{-1}\| \frac{\|\Delta\{\mathbf{b}\}\|}{\|\{\mathbf{b}\}\|}.$$



**Matricos sąlygotumo skaičius. Gerai, jeigu artimas 1; blogai, jeigu labai didelis**

# Matricos sąlygotumo skaičiaus apskaičiavimas

Matricos tikrinės  
reikšmės

$$\|[\mathbf{A}]\| \cdot \|[\mathbf{A}]^{-1}\|$$

$$\det([\mathbf{A}] - \sigma[\mathbf{E}]) = 0 \Rightarrow \sigma_1, \sigma_2, \dots, \sigma_n$$

$$\|[\mathbf{A}]\| \cdot \|[\mathbf{A}]^{-1}\| = \frac{\max_{1 \leq i \leq n} \sigma_i}{\min_{1 \leq i \leq n} \sigma_i}$$

MATLAB-e:

`norm(A)* norm(inv(A))`

`cond(A)`

# Matricų sąlygotumo skaičių pavyzdžiai

norm1=norm(A)\*norm(inv(A))

norm2=cond(A)

$$\frac{\|\Delta \{\mathbf{x}\}\|}{\|\{\mathbf{x}\}\|} \leq \|[\mathbf{A}]\| \cdot \|[\mathbf{A}]^{-1}\| \frac{\|\Delta \{\mathbf{b}\}\|}{\|\{\mathbf{b}\}\|}$$

A =

5	0	0
0	5	0
0	0	5

norm1 = 1

norm2 = 1

A =

1	2	-3
-4	5	6
7	-8	9

norm1 = 6.9511

norm2 = 6.9511

A =

1.0000	2.0000	3.0100
1.0000	2.0000	3.0000
1.0100	2.0000	3.0000

norm1 = 1.9890e+003

norm2 = 1.9890e+003

A =

1	0	0
0	5	0
0	0	9

norm1 = 9

norm2 = 9

A =

11	-5	12
6	-2	10
0	13	29

norm1 = 70.7940

norm2 = 70.7940

A =

1.0000	2.0000	3.0001
1.0000	2.0000	3.0000
1.0001	2.0000	3.0000

norm1 = 1.9850e+005

norm2 = 1.9850e+005



# Sprendinio tikslumo pagerinimas

Jeigu gauto sprendinio tikslumas nepatenkinamas, jį galima pagerinti taip:

